

BORSANEURON: ALGORİTMİK HİSSE SENEDİ FİYAT TAHMİNLEMESİ VE OTOMATİK TEKNİK ÖRÜNTÜ TARAYICI PLATFORMU

<https://github.com/zachariatrying/borsaneuron>

Lisans Tezi

hazırlayan

İbrahim Tatar

20211314007

Tez Danışmanı: Dr. Öğr. Üyesi UĞUR TEVFİK KAPLANCALI

■STANBUL, BAHAR 2026

İÇİNDEKİLER

- ÖZ 2
- ABSTRACT 3
 - 1. GİRİŞ 4
 - 1. PROJE KURULUMU 5
- 2.1. Kurulum Öncesi Gerekli Yazılımlar 5
- 2.2. Projenin Başlangıç Kurulum Paketleri 6
 - 1. BORSANEURON PLATFORMU VE MODÜLLERİNİN İNŞASI 8
- 3.1. Nicel Veri Hattı 8 * 3.1.1. Pearson Korelasyon Filtrelemesi 8 * 3.1.2. K-Means Pazar Segmentasyonu 10 * 3.1.3. LZMA xz Veri Sıkıştırma Çözümü 12
- 3.2. Denetimli Makine Öğrenmesi Motorları 14 * 3.2.1. Hiperparametre Optimizasyonu (K-NN ve GridSearchCV) 14 * 3.2.2. Random Forest Gini Özellik Önem Dereceleri 16 * 3.2.3. Yapay Sinir Ağları (ANN MLPClassifier) 18 * 3.2.4. Üretim Amaşı XGBoost Sınıflandırma Modeli 20
- 3.3. Streamlit İstatistisi Arayüzü 22 * 3.3.1. Glassmorphic SaaS Düzeni ve Özel CSS Enjeksiyonu 22 * 3.3.2. Canlı Hisse Sorgulama Sayfası ve yfinance Çekimi Hattı 24 * 3.3.3. Tarihsel Başarı Oranı (Win Rate) Karar Motoru 26 * 3.3.4. Sektörel Akran Karşılaştırması 28 * 3.3.5. İnteraktif Grafik Görselleştirici (Plotly) 30 * 3.3.6. Canlı Portföy Simülasyonu 32
- 3.4. Otomatik Geometrik Formasyon Tanıma Motoru 34 * 3.4.1. ZigZag İndikatörü ile Tepe ve Dip Noktalarının Çıkarılması 34 * 3.4.2. Omuz-Baş-Omuz (OBO) ve Ters Omuz-Baş-Omuz (TOBO) Formasyonları 35 * 3.4.3. Çanak-Kulp ve Bayrak Formasyonları 36 * 3.4.4. İkili Dip ve İkili Tepe Formasyonları 37
- 1. PROJENİN YAYINA ALINMASI VE DAĞITIMI 38
- 4.1. Docker ile Konteynerleştirme 38
- 4.2. Canlı Sunucu Kurulumu ve Çalıştırma Komutları 39
 - 1. DOSYA HİYERARŞİSİ 39
 - 1. KISITLAR VE GELECEK ÇALIŞMALAR 40
- TEKNOLOJİ YİĞİTİ 41
- KAYNAKÇA 42

ÖZ

Bu çalışmada, Borsa İstanbul (BIST) hisse senedi piyasalarında işlem gören hisse senetlerinin teknik analiz indikatörleri ve geometrik fiyat örüntülerini kullanarak, 5 günlük gelecek fiyat yönünü tahmin etmeyi ve klasik grafik formasyonların otomatik olarak taramayı hedefleyen bütünsel bir karar destek platformu olan **BorsaNeuron**'u sunmaktadır.

Geliştirilen bu proje, Borsa İstanbul genelini temsil eden **aktif BIST hisse senetlerine** ait tarihsel günlük veriler üzerinde yürütülmüştür. Modelleme verimliliğini ve doğruluğunu artırmak amacıyla, 30 teknik indikatör derinliklerinden oluşan zengin bir özellik seti oluşturulmuş ve gelecek sızıntısı (look-ahead bias) engellenmiştir. Derinlikler arasında çoklu doğrusal bağılantıyı önlemek adına korelasyon analizleri yapılarak yüksek derecede ilişkili özellikler elenmiştir. K-Means kümeleme algoritması kullanılarak pazarın teknik durumları ve indikatör rejimleri 5 farklı kümede gruplandırılmış; bu kümelerin dağılımları Temel Bileşenler Analizi (PCA) ile 2 boyutlu uzayda görselleştirilmiştir (PC1 ve PC2 toplam varyansın %52.25'ini açıklamaktadır).

BIST hisselerinin 5 gün sonraki kapanış fiyatının bugünkünden yüksek olup olmayacağını (Target_T5) tahmin etmek üzere K-En Yakın Komşu (K-NN), Yapay Sinir Ağları (ANN - MLPClassifier), Rastgele Orman (Random Forest) ve XGBoost modelleri değerlendirilmiştir. Yapay Sinir Ağı (ANN) %55.68 doğruluk ve 0.6496 F1-Skor ile en yüksek tahminsel başarıyı sergilerken; genişletilmiş veri setinde kullanılan XGBoost modeli dengeli duyarlılık ve kesinlik metrikleriyle online tahmin motoru olarak seçilmiştir.

Yapay zeka modelleri, Python Streamlit kütüphanesi kullanılarak interaktif bir web kontrol paneline (BorsaNeuron Dashboard) dönüştürülmüştür. Bu arayüz; kullanıcıların hisse kodu girerek yfinance üzerinden akan canlı teknik verilerle anlık çıkarım tahminleri alabildiği, hisselerin **kendi geçmişi, başarı uyumunu (Win Rate)** karar alma sürecine aktararak entegre ettiği ve TOBO, Fincan-Kulp, Flama, İkili Dip ve İkili Tepe gibi klasik formasyonları BIST genelinde tarayabildiği canlı bir platform sunmaktadır. Geliştirilen platform, Dockerfile ile konteynerleştirilmiş ve bulut ortamında yaygınlaştırmaya hazır hale getirilmiştir. GitHub dosya boyutu limitlerini aşmak amacıyla 318MB boyutundaki veri seti, xz formatında sıkıştırılarak 50.1MB'a düşürülmüş ve çalışmada zamanında dinamik olarak okunacak şekilde entegre edilmiştir.

Anahtar Kelimeler: Veri Madenciliği, BIST Tahminlemesi, Makine Öğrenmesi, K-Means Kümeleme, Sektörel Kuyaslama, Streamlit, Teknik Formasyon Tarayıcı.

ABSTRACT

This study presents **BorsaNeuron**, a holistic decision support and analytics workstation designed to forecast the 5-day future price direction of equities and automate the scanning of classical chart patterns in the Borsa Istanbul (BIST) stock market.

The project was developed utilizing historical daily market data representing active equities listed on Borsa Istanbul. To enhance modeling efficiency and accuracy, a rich feature set consisting of 30 technical indicators was engineered while carefully avoiding look-ahead bias. To address collinearity among the variables, correlation analysis was executed, and highly correlated features were pruned. A K-Means clustering algorithm partitioned the technical indicator states into 5 unique market regimes, which were subsequently projected and visualized in a 2D space using Principal Component Analysis (PCA) (where PC1 and PC2 explain 52.25% of the total cumulative variance).

To forecast whether a stock's closing price in 5 days will be higher than its current price (Target_T5), K-Nearest Neighbors (K-NN), Artificial Neural Networks (ANN - MLPClassifier), Random Forest (RF), and XGBoost classifiers were optimized and evaluated. The Artificial Neural Network (ANN) demonstrated the highest predictive performance during out-of-sample testing with a 55.68% accuracy and a 0.6496 F1-Score, while the final high-dimensional production model utilized the XGBoost Classifier for its robust precision-recall profile.

The machine learning models were integrated into an interactive web dashboard developed using the Python Streamlit library. The dashboard provides a live interface where users can query BIST tickers, receive real-time inference predictions using data streamed via yfinance, modulate risk thresholds based on the stock's **unique historical win rate**, and trigger automated scanners for classical patterns such as Head and Shoulders (OBO/TOBO), Cup and Handle, Flag, Pennant, Double Bottom, and Double Top formations. The entire platform was containerized using Docker to ensure seamless cloud deployment. To circumvent GitHub's file size limits, the 318MB raw dataset was compressed using the LZMA (xz) algorithm to 50.1MB, and is decompressed dynamically in-memory on system startup.

Keywords: Data Mining, BIST Price Forecasting, Machine Learning, K-Means Clustering, Sector Benchmarking, Streamlit, Technical Pattern Scanner.

1. GİRİŞ

Bu çalışmada, teknik analiz indikatörlerini ve makine öğrenmesi algoritmalarını kullanarak Borsa İstanbul (BIST) pay piyasalarındaki hisse senetlerinin 5 günlük gelecek fiyat yönünü tahmin etmeyi ve klasik grafik formasyonların otomatik olarak taramayı amaçlayan bütünsel bir karar destek ve veri analiz arayüzü olan **BorsaNeuron** platformunu sunmaktadırlar.

Kantitatif finans ve veri madenciliği prensiplerinin uygulandığı bu projede, Borsa İstanbul bünyesinde işlem gören aktif hisselerle ait geniş bir tarihsel veri havuzu kullanılmıştır. Geliştirilen veri mühendisliği hatları öncelikle eksik verileri temizlemiş, ardından değişkenler arasında \$0.90\$ eğerini alan çoklu doğrusal bağılantıyı önlemek için Pearson korelasyon analizi gerçekleştirilmiştir. Piyasadaki farklı teknik koşullar ve rejimleri yakalamak amacıyla, K-Means kümeleme algoritması indikatör durumlarının 5 benzersiz kümeye bölmüştür. Bu kümeler daha sonra Temel Bileşenler Analizi (PCA) yardımıyla iki boyutlu bir özellik uzayına yansıtılmış ve PC1 ile PC2'nin toplam varyansın %52.25'ini açıkladığını gösterilmiştir.

Hisselerin 5 günlük fiyat yönü hedefini (Target_T5) tahmin etmek üzere K-En Yakın Komşu (K-NN), Yapay Sinir Ağları (ANN - MLPClassifier) ve Rastgele Orman (RF) modelleri optimize edilmiştir. Yapay Sinir Ağı (ANN) modeli %55.68 doğruluk oranı ve 0.6496 F1-Skoru ile test verilerinde en yüksek genel tahminsel doğruluğu sergilemiştir. Sistem verilerinin Haziran 2026 dönemine kadar genişletilmesiyle oluşturulan yüksek boyutlu üretim veri setinde ise dengeli hassasiyet ve duyarlılık (precision-recall) profili nedeniyle XGBoost Sınıflandırma algoritması çevrimiçi tahmin motoru olarak devreye alınmıştır.

Sayısal modelleme hatlarını canlı bir iş zekası aracına dönüştürmek amacıyla, Python Streamlit kütüphanesi kullanılarak interaktif bir web paneli (BorsaNeuron Dashboard) inşa edilmiştir. Platform kullanıcıların BIST hisse kodlarını dinamik olarak sorgulamalarına, yfinance üzerinden akan canlı fiyat verileriyle anlık tahminler üretmelerine, risk eğerlerini hisselerin **tarihsel başarı oranına (Win Rate)** göre ayarlamalarına ve TOBO, OBO, Çanak-Kulp, Flama, İkili Dip ve İkili Tepe gibi geometrik fiyat oluşumlarının otomatik olarak taramalarına olanak tanır. GitHub'ın 100MB'lık dosya yükleme limitini aşmak amacıyla, 318MB boyutundaki ham veri seti LZMA (xz) algoritmasıyla 50.1MB'a sıkıştırılmış ve sistem açıldığında 6 saniyenin altında dinamik olarak bellek üzerinde açılacak şekilde entegre edilmiştir.

Anahtar Kelimeler: Veri Madenciliđi, BIST Tahminlemesi, Makine Öğrenmesi, K-Means Kümeleme, Sektörel Kuyaslama, Streamlit, Teknik Formasyon Taraycđı.

2. PROJE KURULUMU

Projeyi çalıştırmak ve model geliştirme süreçlerini yerel bilgisayarınızda tekrarlayabilmek için öncelikle uygun veri madenciliği ve programlama ortamının kurulması gerekmektedir. Bu araçlar bize veri önleme komut dosyalarını çalıştırmak, modelleri eğitmek ve web panelini yayına almak için kararlı bir terminal sağlar. Kurulum adımlarının ardından terminal aracılığıyla paket yüklemeleri gerçekleştirilecektir.

2.1. Kurulum Öncesi Gerekli Yazılımlar

Sistem kararlılığını ve platformlar arası uyumluluğu sağlamak adına BorsaNeuron standart yazılım ortamlarının temel alması: * **Python v3.9 veya v3.11:** Veri madenciliği kütüphanelerinin olgunluğu ve Streamlit arayüz bileşenlerinin kararlılığı sebebiyle tercih edilmiştir. * **Visual Studio Code (VS Code) IDE:** Kod geliştirme, paket hata ayıklama ve yerel test çalıştırmalarında ana geliştirme ortamı olarak kullanılmaktadır. * **Git Sürüm Kontrol Sistemi:** Kodların versiyonlanması, yerel commit süreçleri ve GitHub uzak deposu ile senkronizasyon için kurulmuştur.

2.2. Projenin Başlangıç Kurulum Paketleri

Kütüphanelerin sürüm çakışmalarını önlemek amacıyla izole bir sanal ortam oluşturulmuştur. Başlangıçlıklar `requirements.txt` dosyasında şu şekilde tanımlanmıştır:

```
pandas>=1.5.0
numpy>=1.22.0
scikit-learn>=1.1.0
streamlit>=1.22.0
matplotlib>=3.5.0
seaborn>=0.11.0
joblib>=1.1.0
yfinance>=0.2.0
plotly>=5.10.0
xgboost>=1.6.0
```

Sanal ortamın yapılandırılması ve kütüphanelerin yüklenmesi için sırasıyla şu terminal komutları yürütülmüştür:

```
# Sanal ortam oluşturma
python -m venv borsaneuron_env

# Sanal ortamı aktive etme (Windows PowerShell için)
.\borsaneuron_env\Scripts\Activate.ps1

# Pip paket yöneticisini güncelleme
python -m pip install --upgrade pip

# Proje kütüphanelerini yükleme
pip install -r requirements.txt
```

3. BORSANEURON PLATFORMU VE MODÜLLERİNİN İNŞASI

3.1. Nicel Veri Hattı


3.1.1. Pearson Korelasyon Filtrelemesi

Fiyat serilerinden üretilen teknik indikatörler doğası gereği yüksek düzeyde çoklu doğrusal bağımlılık (multicollinearity) gösterir. Örneğin, kısa vadeli ve uzun vadeli hareketli ortalamalar (SMA_20 ve EMA_12) oldukça paralel hareket eder. Bu durum, veri seti içindeki bağımlı değişkenlerin varyansın bozarak K-NN veya doğrusal temelli modellerde kararsız tahmin katsayılarına ve aşırı öğrenmeye yol açar.

Bu sorunu çözmek amacıyla, veri setindeki 30 teknik indikatörün tamamı arasında Pearson Korelasyon Matrisi oluşturulmuştur. Korelasyon katsayıları 0.90'dan yüksek olan değişken çiftleri belirlenmiştir:

$$|r_{ij}| > 0.90$$

Oluşturulan üst üçgen matris filtresi aracılığıyla birbirini tekrar eden yüksek korelasyonlu değişkenler elenmiştir. Böylece veri setinin boyutsal karmaşıklığı azaltılırken, modellerimizin temiz ve bağımlı sinyaller alması sağlanmıştır.




Şekil 3.1: Teknik indikatörler arasındaki Pearson korelasyon seviyelerini gösteren ısı haritası.

3.1.2. K-Means Pazar Segmentasyonu

Gözetimsiz öğrenme metodolojisi kapsamında K-Means algoritması uygulanarak, hisse senetlerinin teknik gösterge durumlarına göre pazar rejimleri kümelendirilmiştir. Kümeleme öncesinde verilerin normalize edilmesi sağlanmıştır:

$$z = \frac{x - \mu}{\sigma}$$

Optimum küme sayısının matematiksel olarak doğrulamak üzere Elbow (Dirsek) analizi yapılmıştır. Küme sayısı arttıkça grup içi hata kareler toplamındaki (inertia) düşüş hızı incelenmiş ve inertia değerinin büküldüğü dirsek noktası olan $k=5$ optimum küme sayısı olarak seçilmiştir.



Şekil 3.2: Küme sayılarına göre inertia düşüş hızını gösteren Elbow metodu grafiği.

Küme ayrıştırmak ve yüksek boyutlu indikatör uzayını görselleştirmek adına Temel Bileşenler Analizi (PCA) yürütülmüştür. Elde edilen ilk iki temel bileşen (PC1 ve PC2), toplam varyansın %52.25'ini tek başına açıklamaktadır.

Bu mimari yaklaşımlar sayesinde dosya boyutu %84 oranında azaltılarak GitHub limitlerinin altına çekilmiş, sistemin yerel diskten okuma ve belleğe yükleme süresi ise 5.7 saniye gibi son derece verimli bir seviyede tutulmuştur.

3.2. Denetimli Makine Öğrenmesi Motorları


3.2.1. Hiperparametre Optimizasyonu (K-NN ve GridSearchCV)

K-En Yakın Komşu (K-NN) algoritması, veri noktalarının mesafe benzerliklerine dayalı olarak sınıflandırma yapan bir yöntemdir. Mesafe hesaplamaları bakımından deyimlerin ölçeklerine aşırı duyarlı olduğundan, özellikler öncelikle normalize edilmiş (X_{scaled}) şekilde modele sunulmuştur.

K komşuluk parametresinin en iyi değerini bulmak için 5 katlı çapraz doğrulama (5-fold cross-validation) ile geniş bir hiperparametre arama uzayı tanımlanmıştır:

$$\text{Arama Uzayı} = k \in \{3, 5, 7, 9, 11, 15, 21\}$$

GridSearchCV optimizasyonu sonucunda, aşırı öğrenmeyi (overfitting) en aza indiren ve en yüksek çapraz doğrulama başarılarını veren komşuluk parametresi $k=21$ olarak belirlenmiş ve %54.01 test doğruluğu elde edilmiştir.




Şekil 3.4: K-NN modelinde komşuluk sayısına göre çapraz doğrulama doğruluk oranları.

3.2.2. Random Forest Gini Özellik Önem Dereceleri

İkinci olarak eleştirilen model olan Rastgele Orman (Random Forest) senin flandörçsünde 100 karar ağacından oluşan bir orman yapısı kurulmuştur. Random Forest modeli test verileri üzerinde %53.35 doğruluk oranı ve 0.6367 F1-Skoru sergilemiştir.

Hisse senedi fiyat yönü tahmininde en belirleyici teknik göstergeleri tespit etmek amacıyla karar ağaçlarındaki Gini saflık derecesi azalışları (Gini impurity decrease) izlenmiştir. Yapılan analizde, işlem hacmi trendi (Volume), açılış fiyatı (Open) ve RSI_14 momentum göstergesinin BIST fiyat yönü tahminlemesinde en yüksek bilgi kazancını sağlayan ilk üç özellik olduğu saptanmıştır.



Şekil 3.5: Karar ağaçlarında Gini saflığına göre belirlenen ilk 15 özellik önem sıralaması.

3.2.3. Yapay Sinir Ağları (ANN MLPClassifier)

Doğrusal olmayan daha karmaşık desenleri yakalamak amacıyla Çok Katmanlı Algılayıcı (Multi-Layer Perceptron) yapısında bir Yapay Sinir Ağı (ANN) mimarisi tasarlanmıştır. Model mimarisi şu parametrelerle yapılandırılmıştır: * **Gizli Katman Yapısı:** Sırasıyla 64, 32 ve 16 nöron içeren üç katmanlı (64, 32, 16) yapı. * **Aktivasyon Fonksiyonu:** Doğrusal olmayan geçişleri modellemek için Rectified Linear


Unit (ReLU). * **Optimizasyon Çözücü:** Gradyan ini h z n ayarlamak için Adam çözücü ve 128 batch boyutu. * **Maksimum Epok:** Kararlı bir yakınsama için 100 epoch.

Yapay Sinir Ağı modeli test verilerinde yüksek başarı göstererek %55.68 doğruluk oranı ve 0.6496 F1-Skoru elde etmiştir.

3.2.4. Üretim Aşaması XGBoost Sınıflandırma Modeli

BorsaNeuron platformunun çevrimiçi canlı tahmin motoru olarak XGBoost algoritması seçilmiştir. Yapay Sinir Ağı (ANN) ham doğrulukta biraz daha yüksek görünse de (%55.68 vs %51.31), XGBoost modeli daha dengeli bir Precision-Recall (Hassasiyet-Duyarlılık) profili sunarak F1-Skorunu kararlı kılmıştır. Finansal trading sistemlerinde 'false positive' (yükselecek tahmini verilip düşen hisse) dorudan sermaye kaybına yol açtığı için, XGBoost'un yüksek hassasiyetli yapısı tercih edilmiştir.

Üretim aşamasındaki XGBoost modelinin özellik önem analizinde ilk sıraları şu teknik göstergeler almıştır: 1. **Resistance_Level** (%5.71) — Direnç kırılım hatları. 2. **Support_Level** (%5.60) — Fiyat taban destek seviyeleri. 3. **Pat_Yok** (%5.58) — Belirgin bir geometrik formasyonun bulunmadığı yatay dönemler. 4. **Pat_OBO** (%5.27) — Omuz-Bağ-Omuz düşüş formasyon sinyali. 5. **SMA_50** (%5.26) — Orta vadeli kurumsal eğilim göstergesi. 6. **SMA_200** (%5.10) — Uzun vadeli kurumsal destek ve ana eğilim çizgisi. 7. **Pat_TOBO** (%5.05) — Borsa piyasası dönüş sinyali olan Ters OBO formasyonu. 8. **BB_Middle** (%4.90) ve **BB_Lower** (%4.89) — Bollinger Bantları volatilité sınırları.




Şekil 3.6: Eğitimlenen makine öğrenmesi modellerinin Doğruluk ve F1-Skoru metriklerine göre karşılaştırma grafiği.

3.3. Streamlit Web Stasyonu Arayüzü

3.3.1. Glassmorphic SaaS Düzeni ve Özel CSS Enjeksiyonu

Sayısal modellerin son kullanıcı tarafından kullanılabilmesi amacıyla, Streamlit kütüphanesi üzerinde özelleştirilmiş bir web paneli geliştirilmiştir. Kullanıcı deneyimini (UX) artırmak adına, modern trading terminallerine uygun koyu tema (dark mode) üzerinde yapıldı saydam cam efekti (glassmorphism) sunan özel CSS kodları tasarlanarak uygulamaya enjekte edilmiştir.

Web arayüzünün sol tarafındaki navigasyon barı şu sayfaları içerir: 1. **Karşılama Paneli (Welcome Dashboard):** Sistemin genel durumunu, aktif makine öğrenmesi parametrelerini, veri seti özetini ve genel kullanım rehberini içerir. 2. **Canlı Hisse Tahmini (Live Stock Forecasting):** Kullanıcının hisse kodu girerek yapay zeka çıkarımlarının canlı fiyat verileriyle izlediği ana ekrandır. 3. **Otomatik Formasyon Tarayıcı (Automated Pattern Scanner):** BIST genelinde formasyon oluşturan hisseleri tarayan ve listeleyen ekrandır.



■ekil 3.7: BorsaNeuron interaktif SaaS kar■lama arayüzü.

3.3.2. Canl■ Hisse Sorgulama Sayfas■ ve yfinance Ç■kar■m Hatt■

Kullan■c■ arayüz üzerinden bir BIST hisse kodu sorgulad■■nda, Streamlit arka planda yfinance üzerinden hissenin son 1 y■ll■k günlük mum verilerini indirir. Teknik indikatör vektörünü hesaplad■ktan sonra best_scaler_acm465.joblib ile normalize eder ve best_model_acm465.joblib MLP modeline göndererek anl■k ç■kar■m (inference) tahmini üretir:


```
# Canl■ veri çekme ve model ç■kar■m hatt■
import yfinance as yf
import joblib

scaler = joblib.load("best_scaler_acm465.joblib")
model = joblib.load("best_model_acm465.joblib")

def get_live_forecast(ticker):
    df_live = yf.download(ticker, period="1y", interval="1d")
    feature_vector = compute_technical_vector(df_live)
    scaled_vector = scaler.transform([feature_vector])
    prediction = model.predict(scaled_vector)[0]
    probability = model.predict_proba(scaled_vector)[0][1]
```

return prediction, probability

Bu veri hattı sayesinde web panelinde anlık piyasa verilerine dayalı kararlar saniyeler içinde üretilmektedir.



Şekil 3.8: Canlı hisse sorgulama ve yapay zeka tahmin paneli arayüzü.

3.3.3. Tarihsel Başarı Oranı (Win Rate) Karar Motoru

BorsaNeuron'un en özgün özelliklerinden biri olan **Tarihsel Başarı Oranı Karar Motoru**, makine öğrenmesi modelinin her hisse senedinde aynı kararlara ulaşmaya çalışması üzerine kurulmuştur. Sistem, sorgulanan hissenin son 1 yıllık tarihsel verisinde modelin ürettiği alım sinyallerinin geriye dönük doğruluk oranının hesaplar:

$$\text{Başarı Oranı} = \frac{\text{Doğru Çıkan Yükseliş Sinyalleri}}{\text{Toplam Üretilen Yükseliş Sinyalleri}} \times 100$$

Bu değer karar sürecine bir filtre olarak eklenir. Eğer hissenin tarihsel başarı oranı %60'tan büyükse modele ek alım onayı verilir, %48'in altındaysa sistem kullanıcıya yüksek risk uyarısı gösterir.

3.3.4. Sektörel Akran Karşılaştırması


Platform sorgulanan hisseyi kendi sektörüyle (Bankacılık, Sanayi, Enerji, Ulaştırma vb.) gruplandırarak, hissenin mevcut teknik göstergelerini (RSI, Hacim Trendi vb.) sektör ortalamalarıyla karşılaştırır. Bu sayede makro düzeyde sektörel bir karşılaştırma imkanı sunulur.

3.3.5. İnteraktif Grafik Görselleştirici (Plotly)


BorsaNeuron, Bollinger Bantları ve hareketli ortalamalarla zenginleştirilmiş etkileşimli bir Plotly ortamdan (candlestick) grafiği çizer. Grafiğin üzerinde, yapay zekanın geçmişte ürettiği kararların alım noktaları yeşil yukarı yönlü üçgenlerle dinamik olarak işaretlenir.

3.3.6. Canlı Portföy Simülasyonu


Arayüze entegre edilmiş portföy simülatörü, başlangıçta 100.000 TL sermaye ile yola çıkıldığında **BorsaNeuron Yapay Zeka Stratejisi vs. Al ve Tut (Buy & Hold)** getirileri ve risklerini son 1 yıllık tarihsel veri üzerinde karşılaştırmalı olarak simüle eder.




Şekil 3.9: Streamlit dinamik simülasyon kayıtları ve senaryo analizi paneli.



Şekil 3.10: K-Means kümeleme profillerinin indikatör yorumluk analiz grafiği.



Şekil 3.11: Canlı Prophet zaman serisi fiyat tahmin arayüzü.



Şekil 3.12: BorsaNeuron yapay zeka sinyalleri ile Al ve Tut stratejisinin getiri karıllanma grafiği.

3.4. Otomatik Geometrik Formasyon Tanıma Motoru

3.4.1. ZigZag İndikatörü ile Tepe ve Dip Noktalarının Çıkarılması

İndikatör tahminlerine ek olarak, BorsaNeuron `src/analyzer.py` modülünde yer alan matematiksel bir formasyon tarayıcısı içerir. Tarayıcı, fiyat hareketlerindeki %5'in altındaki küçük gürültüleri filtreleyerek yerel tepe ve dip noktalarını (extrema) çıkaran bir ZigZag algoritması kullanır. Tespit edilen bu pivot noktaları geometrik ekle kurallara tabi tutularak klasik formasyonlar taranır.

3.4.2. Omuz-Başı-Omuz (OBO) ve Ters Omuz-Başı-Omuz (TOBO) Formasyonları

- **TOBO (Ters Omuz-Başı-Omuz):** Yan yana oluşan üç ardışık dip noktası (L_1 , L_2 , L_3) analiz edilir. Ortadaki dip noktasının (Başı) sağ ve soldaki diplerden (Omuzlar) daha aşağıda olması şartı aranır: $L_2 < L_1$ ve $L_2 < L_3$. Bu diplerin arasındaki tepelerden geçen boyun çizgisinin eğimi kontrol edilerek kırılımı teyit edilir.
- **OBO (Omuz-Başı-Omuz):** Üç ardışık tepe noktası (H_1 , H_2 , H_3) kullanılarak ters mantık iletilir: $H_2 > H_1$ ve $H_2 > H_3$. Boyun çizgisinin aşağı yönlü kırılması durumunda düşüş sinyali üretilir.

3.4.3. Çanak-Kulp ve Bayrak Formasyonları

- **Çanak-Kulp:** U şeklinde geni bir çanak dip yapısı ve ardından gelen daha sığ bir kulp konsolidasyonu aranır. Çanağın derinliği şu koşulu sağlamalıdır:
$$\text{Çanak Derinliği} = \frac{\text{Çanak Kenarı} - \text{Çanak Dibi}}{\text{Çanak Kenarı}} \in [0.15, 0.50]$$
 Kulp yapısı çanak derinliğinin %50'sinden daha fazla aşılmamalıdır.
- **Bayrak:** Fiyatta görülen sert ve dikey bir yükselişin (bayrak direği) ardından oluşan dar ve paralel bir konsolidasyon kanalı (bayrak) tespit edilir. Kanalin yukarı yönlü kavrılması trendin devam edeceğini teyit eder.

3.4.4. İkili Dip ve İkili Tepe Formasyonları

- **İkili Dip:** İki ardışık dip noktasının (L_1 , L_2) birbirine çok yakın fiyat seviyelerinde oluşması koşulu aranır. Yatay tolerans limiti maksimum %2 olarak belirlenmiştir:
$$\left| \frac{L_1 - L_2}{\min(L_1, L_2)} \right| \leq 0.02$$
 Aradaki tepenin oluşturduğu direnç boyun çizgisinin (H_1) yukarı yönlü geçilmesiyle formasyon tetiklenir:
$$\text{Kapan Fiyat} > H_1$$
- **İkili Tepe:** İki ardışık tepe noktasının (H_1 , H_2) yaklaştık ayni direnç seviyesinde oluşması durumudur:
$$\left| \frac{H_1 - H_2}{\min(H_1, H_2)} \right| \leq 0.02$$
 Aralarındaki dip noktası olan boyun desteğinin (L_1) aşılması yönlü kavrılması formasyonu onaylar:
$$\text{Kapan Fiyat} < L_1$$

4. PROJENİN YAYINA ALINMASI VE DAĞITIMI

Geliştirilen BorsaNeuron yazılımının geliştirici bilgisayarlarında ve canlı sunucu ortamlarında tutarlı bir şekilde çalışabilmesi amacıyla Docker konteynerizasyonu uygulanmıştır.

4.1. Docker ile Konteynerleştirme

Sistem başlımlarının izole eden ve hafif bir çalışma ortamı sunan Dockerfile hazırlanmıştır:

```
FROM python:3.9-slim
ENV PYTHONDONTWRITEBYTECODE=1
ENV PYTHONUNBUFFERED=1
WORKDIR /app
RUN apt-get update && apt-get install -y build-essential curl software-properties-common
COPY requirements.txt .
RUN pip install --no-cache-dir -r requirements.txt
COPY . .
EXPOSE 8501
HEALTHCHECK CMD curl --fail http://localhost:8501/_stcore/health
ENTRYPOINT ["streamlit", "run", "src/app.py", "--server.port=8501", "--server.address=0.0.0.0"]
```

4.2. Canlı Sunucu Kurulumu ve Çalıştırma Komutları

Docker imajının oluşturmak ve konteyneri arka planda çalıştırmak için sırasıyla şu komut satırları kullanılır:

```
# Docker imajın derleme
docker build -t borsaneuron-app:latest .

# Port yönlendirmesi yaparak konteyneri arka planda (detached) başlatma
docker run -d -p 80:8501 --name borsaneuron-prod borsaneuron-app:latest
```

Bu sayede Streamlit'in varsayılan 8501 portu doğrudan ana makinenin 80 portuna (HTTP) yönlendirilerek web sitesi yayına alınmış olur.

5. DOSYA HİYERARŞİSİ

BorsaNeuron projesinin veri hazırlama, model eğitimi ve Streamlit kullanıcısı arayüzü dosyalarının ayrılan klasör dizini yapısı aşağıda sunulmuştur:

```
C:/Users/ibrah/.gemini/antigravity/scratch/ipo_analyzer/
.
├── .streamlit/
├── config.toml # Streamlit görsel tema ayarları
├── bist_ai_dataset_real_30cols.csv.xz # LZMA ile sıkıştırılmış veri seti (50.1MB)
├── best_scaler_acm465.joblib # Kaydedilmiş standart ölçekleyici araçları
├── best_model_acm465.joblib # Kaydedilmiş MLP Yapay Sinir Ağları
├── acm465_proje.py # Çevrimdışı modelleme ve test komut dosyası
├── requirements.txt # Bağımlı olan Python kütüphaneleri listesi
├── start.bat # Kolay çalıştırma kolaylığı batch dosyası
├── Dockerfile # Docker konteyner yapılandırması
├── src/
│   ├── __init__.py
│   ├── app.py # Streamlit web uygulaması ana dosyası
│   ├── theme.py # Glassmorphic UI renk kodları ve stiller
│   ├── data_manager.py # yfinance veri çekme ve önileme modülü
│   ├── earnings_data.py # Şirket finansal veri modelleri
│   ├── macro_data.py # Makroekonomik göstergeler veri yapıları
│   └── verify_tobo_strict.py # TOBO ve Çanak formasyon test ve tarama kodları
├── tests/
│   └── test_features.py # İndikatör doğruluğunu sağlayan birim testleri
```

6. KISITLAR VE GELECEK ÇALIŞMALAR

BorsaNeuron platformunda kullanılan makine öğrenmesi modelleri ve teknik analiz algoritmaları, tarihsel fiyat hareketleri ve bunlardan türetilen matematiksel indikatörler ile sınırlıdır. Finansal piyasalar, doğası gereği yarı etkin (semi-strong efficient) piyasa yapısındadır ve fiyatlar yalnızca geçmiş verilerden değil, aynı zamanda dışsal faktörlerden de etkilenir.

Platformun Temel Kısıtları: 1. **Makro Faktörler ve Haber Akışları:** TCMB faiz kararları, enflasyon açıklamaları, küresel jeopolitik gerilimler veya şirketlerin KAP'a (Kamuyu Aydınlatma Platformu) bildirdiği ani maddi durum açıklamaları, teknik indikatörlerin ürettiği sinyalleri geçersiz klabilmektedir. 2. **Sözleşme Riski (Look-Ahead Bias):** Canlı işlem esnasında yfinance veri akışındaki anlık gecikmeler veya güncellenmemiş veriler geçici kararsızlıklara yol açabilir.

Gelecek Çalışmalar ve Hedefler: Yapay zeka çıkarımlarının güvenilirliğini artırmak amacıyla, sisteme bir **Doğal Dil İşleme (NLP)** modülü eklenmesi planlanmaktadır. Bu modül, KAP bildirimlerini ve finansal haber başlıklarını canlı olarak tarayarak duygu analizi (sentiment analysis) skorları üretecektir. Elde edilen bu duygu skorları, BorsaNeuron'un teknik analiz modeline birer ek özellik (feature) olarak beslenecek ve teknik veri ile temel veriyi birleştiren hibrit bir karar destek motoru oluşturulacaktır.

TEKNOLOJİ YİĞİNİ

Katman	Kullanılan Teknolojiler	Kullanım Amacı
Programlama Dili	Python v3.9+	Tüm bilimsel hesaplamalar ve ana kod tabanı
Veri Mühendisliği	Pandas, NumPy	Veri ön işleme, dizi operasyonları ve indikatör hesaplamaları
Canlı Veri Akışı	yFinance API	Günlük mum fiyatlarının anlık olarak indirilmesi
Veri Madenciliği	Scikit-learn (K-Means, PCA)	Piyasa segmentasyonu ve boyut azaltma analizi
Yapay Zeka Modelleri	MLPClassifier, RandomForest, K-NN	Gelecek fiyat yönünü tahmin eden sınıflandırıcılar
Model Kaydetme	Joblib	Eğitilen model ve ölçekleyicilerin diske yazılması/okunması
Kullanıcı Arayüzü	Python Streamlit	Koyu tema, glassmorphic SaaS istasyonu arayüzü
Görselleştirme	Plotly Express & Graph Objects	Etkileşimli mum grafikleri, getiri eğrileri, PCA dağılımları

Dağıtım	Docker, Slim Runtime	Sunucu başlatma ve dağıtım ve CI/CD süreçlerinin kolaylaştırılması
----------------	----------------------	--

KAYNAKÇA

- Adebisi, A. A., Adewumi, A. O., & Ayo, C. K. (2014). *Comparison of ARIMA and Artificial Neural Networks Models for Stock Price Prediction*. Journal of Applied Mathematics, 2014, 1-10. <https://doi.org/10.1155/2014/614342>
- Atayurt, O. (2021). *Airbnb Demo Project*. Yeditepe Üniversitesi, Ticari Bilimler Fakültesi, Yönetim Bilişim Sistemleri Bölümü, Lisans Tezi. (Tez Danışmanı: Dr. Öğr. Üyesi Uğur Tefik Kaplanal)
- Bahar, O., & Bilen, K. (2023). *Efficiency Analysis of Technical Analysis Indicators: An Application on Borsa İstanbul Tourism Industry*. Anatolia: Turizm Araştırmalar Dergisi, 34(2), 83-94. <https://doi.org/10.17123/atad.1291666>
- Ding, X., Zhang, Y., Liu, T., & Duan, J. (2015). *Deep learning for event-driven stock prediction*. In *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)* (pp. 2327-2333).
- Htun, H. H., Biehl, M., & Petkov, N. (2023). *Survey of feature selection and extraction techniques for stock market prediction*. Financial Innovation, 9(1), 26. <https://doi.org/10.1186/s40854-022-00441-7>
- Kutlu, G. (2022). *Intelligent Agent to Enhance Search Engine*. Yeditepe Üniversitesi, Ticari Bilimler Fakültesi, Yönetim Bilişim Sistemleri Bölümü, Lisans Tezi. (Tez Danışmanı: Doç. Dr. Uğur Tefik Kaplanal)
- Li, A. W., & Bastos, G. S. (2020). *Stock Market Forecasting Using Deep Learning and Technical Analysis: A Systematic Review*. IEEE Access, 8, 185107-185117. <https://doi.org/10.1109/ACCESS.2020.3030226>
- Lin, Y., Guo, H., & Hu, J. (2018). *An SVM-based approach for stock market trend prediction*. International Journal of Forecasting, 34(3), 452-465. <https://doi.org/10.1016/j.ijforecast.2018.03.001>
- Nassirtoussi, A. K., Aghabozorgi, S., Wah, T. Y., & Ngo, D. C. L. (2014). *Text mining for market prediction: A systematic review*. Expert Systems with Applications, 41(16), 7653-7670. <https://doi.org/10.1016/j.eswa.2014.06.009>
- Nti, I. K., Adebisi, M. O., & Adebisi, A. A. (2020). *A systematic review of fundamental and technical analysis of stock market predictions*. Artificial Intelligence Review, 53(4), 3007-3057. <https://doi.org/10.1007/s10462-019-09754-y>
- Rao, H., & Demirci, M. (2019). *Predicting the Turkish Stock Market BIST 30 Index using Deep Learning*. Uluslararası Mühendislik Araştırma ve Geliştirme Dergisi (UMAGD), 11(1), 253-265. <https://doi.org/10.29137/umagd.425560>
- Sonkavde, G., Dharrao, D. S., Bongale, A. M., Deokate, S. T., Doreswamy, D., & Bhat, S. K. (2023). *Forecasting Stock Market Prices Using Machine Learning and Deep*

Learning Models: A Systematic Review, Performance Analysis and Discussion of Implications. International Journal of Financial Studies, 11(3), 94.
<https://doi.org/10.3390/ijfs11030094>

- Taşkaya, E. (2021). *The Difference between Amazon and Alibaba's Marketing Strategy*. Yeditepe Üniversitesi, Ticari Bilimler Fakültesi, Yönetim Bilişim Sistemleri Bölümü, Lisans Tezi. (Tez Danışmanı: Dr. Öğr. Üyesi Uğur Tevfik Kaplancağı)
- Verma, S., Sahu, S. P., & Sahu, T. P. (2023). *Stock Market Forecasting with Different Input Indicators using Machine Learning and Deep Learning Techniques: A Review*. IAENG International Journal of Computer Science, 50(4), 1-17.